

Analise de Series Temporais - Trabalho 1

Gustavo Hotta (A56865193), Rafael Furlan (A56871487), Ricardo Squassina Lee (A56843646)

1- Utilizando o arquivo “Serie_Dados.csv” realize as seguintes etapas:

```
Serie_Dados <- read.csv("Serie_Dados.csv", sep=";")  
#Serie_Dados
```

a) Crie a série temporal dos retornos Ln, ou seja, $r = \ln(P_{t+1} / P_t)$

```
Serie_Dados.LN <- log(Serie_Dados[2:13]/rbind(NA, Serie_Dados[2:13][-nrow(Serie_Dados[2:13]),]))  
Serie_Dados.LN <- Serie_Dados.LN[-1,]  
#Serie_Dados.LN
```


A maior parte dos estudos financeiros concentram-se na análise de séries temporal dos retornos ao invés do uso da série dos preços dos ativos. A razão de utilizarmos série de retornos tem dois fatores, as informações de retornos atendem aos interesses de investidores e a série de retornos possui propriedades estatísticas mais interessantes do que séries dos preços.

b) Para cada ação construa o histograma dos retornos. Comente o resultado dos histogramas, verifique também o desvio padrão e a média de cada série


Histogramas:

```
par(mfrow = c(2, 2))  
  
for (col in 1:ncol(Serie_Dados.LN)) {  
  hist(Serie_Dados.LN[,col], main = names(Serie_Dados.LN[col]), xlab = "")  
}
```


VALE5




GOLL4




AMBV4




ITUB4




BBDC4




BVMF3

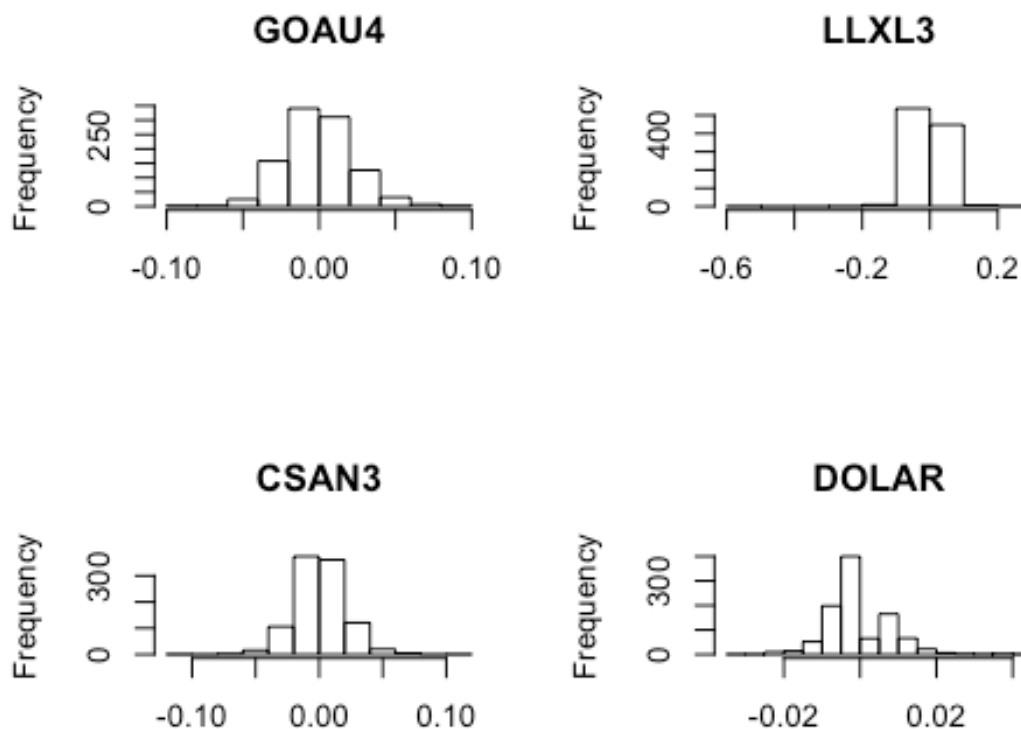


RAPT4



MYPK3





Desvio Padrao e Media:

```
sapply(Serie_Dados.LN, function(c1) list(Media=mean(c1,na.rm=TRUE), DesvioPadrao=sd(c1,na.rm=TRUE)))
```

##	VALE5	GOLL4	AMBV4	ITUB4
## Media	0.0001293889	-0.000491604	0.001271904	-3.197417e-05
## DesvioPadrao	0.01838984	0.0324803	0.01426466	0.01833354
##	BBDC4	BVMF3	RAPT4	MYPK3
## Media	0.000209532	9.431336e-05	0.0003498633	0.001024337
## DesvioPadrao	0.01708826	0.02193809	0.02011623	0.02255594
##	GOAU4	LLXL3	CSAN3	DOLAR
## Media	-0.0001969214	-0.001223711	0.0008827886	0.0002516147
## DesvioPadrao	0.02253222	0.04117323	0.01928199	0.007719852

Graficamente, as variações dos retornos da carteira apresentam uma distribuição normal. Os melhores retornos para os piores são: AMBV4; MYPK3; BVMF3; CSAN3; RAPT4; DÓLAR; BBDC4; VALE5; ITUB4; GOAU4; GOLL4; LLXL3. Os últimos quatro retornos são negativos. Os maiores desvios padrões para os menores são: LLXL3; GOLL4; MYPK3; GOAU4; BVMF3; RAPT4; CSAN3; VALE5; ITUB4; BBDC4; AMBV4; DÓLAR. Podemos analisar que o melhor e mais seguro retorno é a AMBR4, porque tem o melhor retorno e um menor desvio padrão.


c) Calcule o ACF e PACF de cada série de retornos. Comente os resultados.

ACF


```
par(mfrow = c(2, 2))

for (col in 1:ncol(Serie_Dados.LN)) {
  acf(Serie_Dados.LN[,col], main = names(Serie_Dados.LN[col]), xlab = "")
}
```


VALE5




GOLL4




AMBV4




ITUB4




BBDC4




BVMF3




RAPT4




MYPK3




GOAU4




LLXL3



CSAN3



DOLAR




PACF

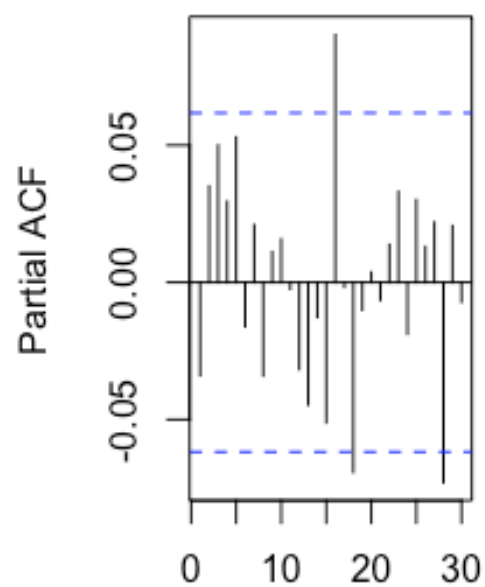
```
par(mfrow = c(1, 2))

for (col in 1:ncol(Serie_Dados.LN)) {
  pacf(Serie_Dados.LN[,col], main = names(Serie_Dados.LN[col]), xlab = "")
}
```


VALE5




GOLL4




AMBV4




ITUB4




BBDC4




BVMF3




RAPT4




MYPK3

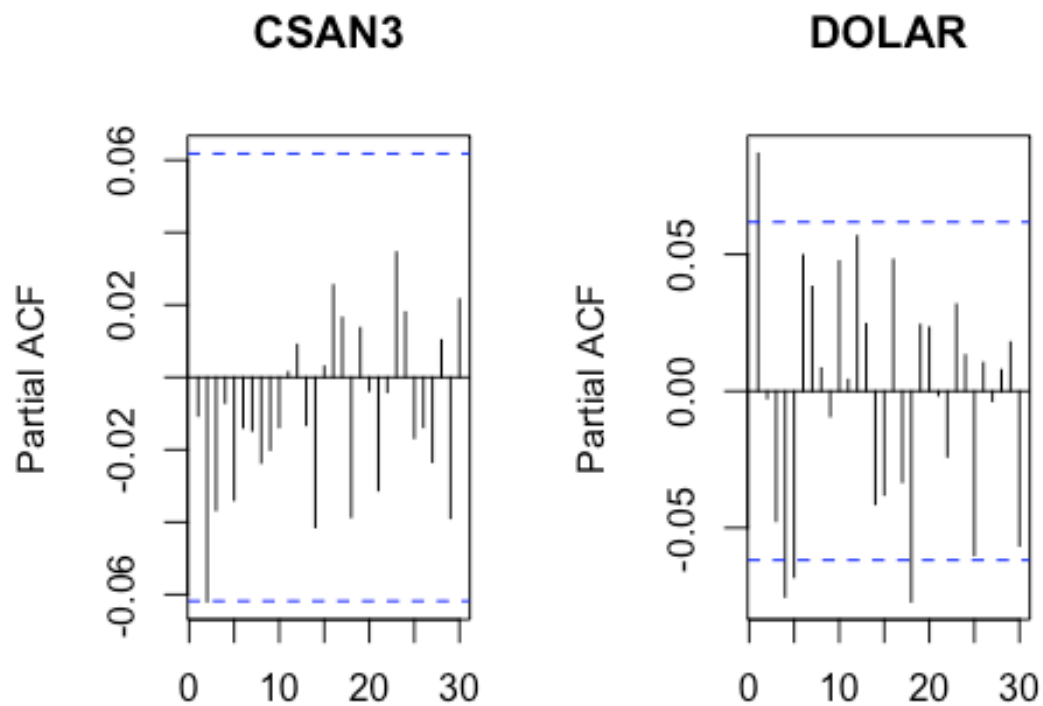


GOAU4



LLXL3





Nos gráficos de ACF, podemos analisar que todos os retornos convergem rapidamente para zero, então podemos concluir que eles são estacionários como $AR(p)$. O PACF (função de autocorrelação parcial) nos dá correlação entre a variável no instante t e uma de suas defasagens, retirando os efeitos das outras defasagens. Graficamente cada retorno apresenta um padrão.

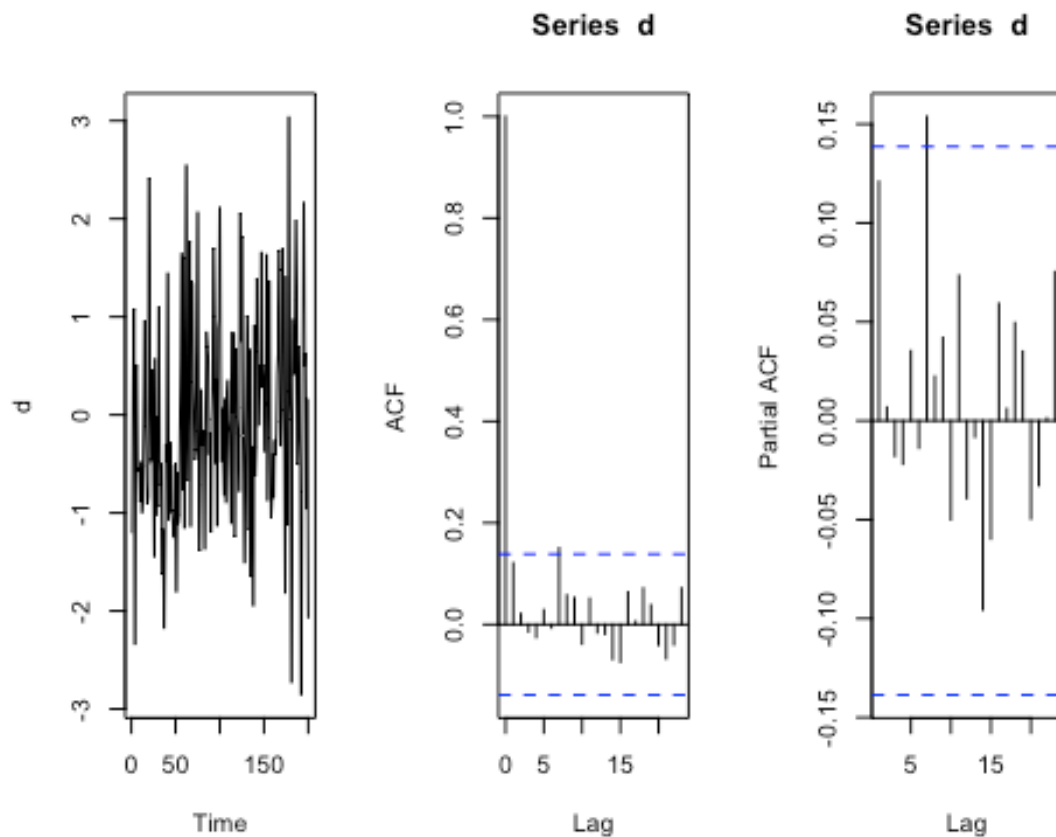
2- Para cada um dos processos abaixo gere 200 observações. Faça um gráfico da série, ACF e PACF. Comente os resultados.

Definindo uma semente para os numeros aleatorios serem sempre os mesmos:

```
set.seed(1234)
```

d) Série aleatória, observações iid da distribuição $N(0,1)$

```
par(mfrow = c(1, 3))  
d <- ts(rnorm(200, 0, 1))  
plot(d)  
acf(d)  
pacf(d)
```



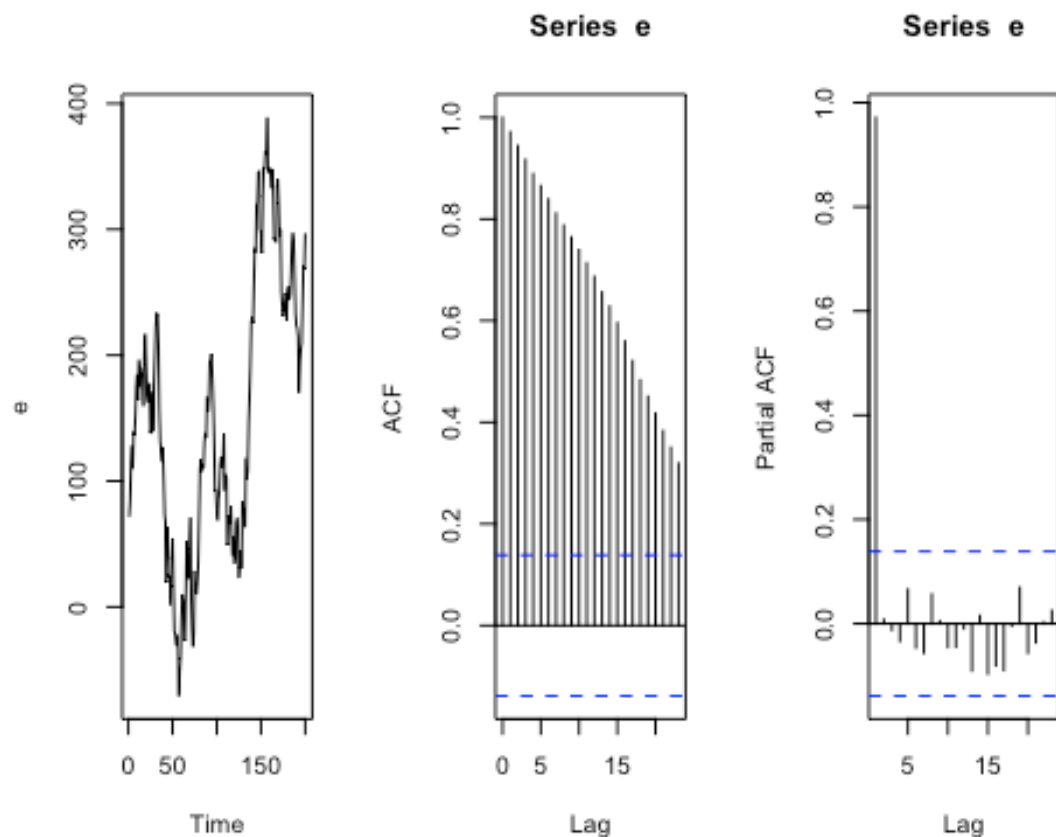
A serie é estacionária, mas por ser iid tem a PACF igual a 0

e) Série com tendência estocástica,

$$x_t = x_{t-1} + N(1, 5^2)$$

Neste caso o coeficiente tem que ser menor que 1 para rodar, então $\alpha = 0.99999$

```
par(mfrow = c(1, 3))  
  
e <- arima.sim(model = list(ar= 0.99999), n=200, innov = rnorm(200,1,25))  
plot(e)  
acf(e)  
pacf(e)
```



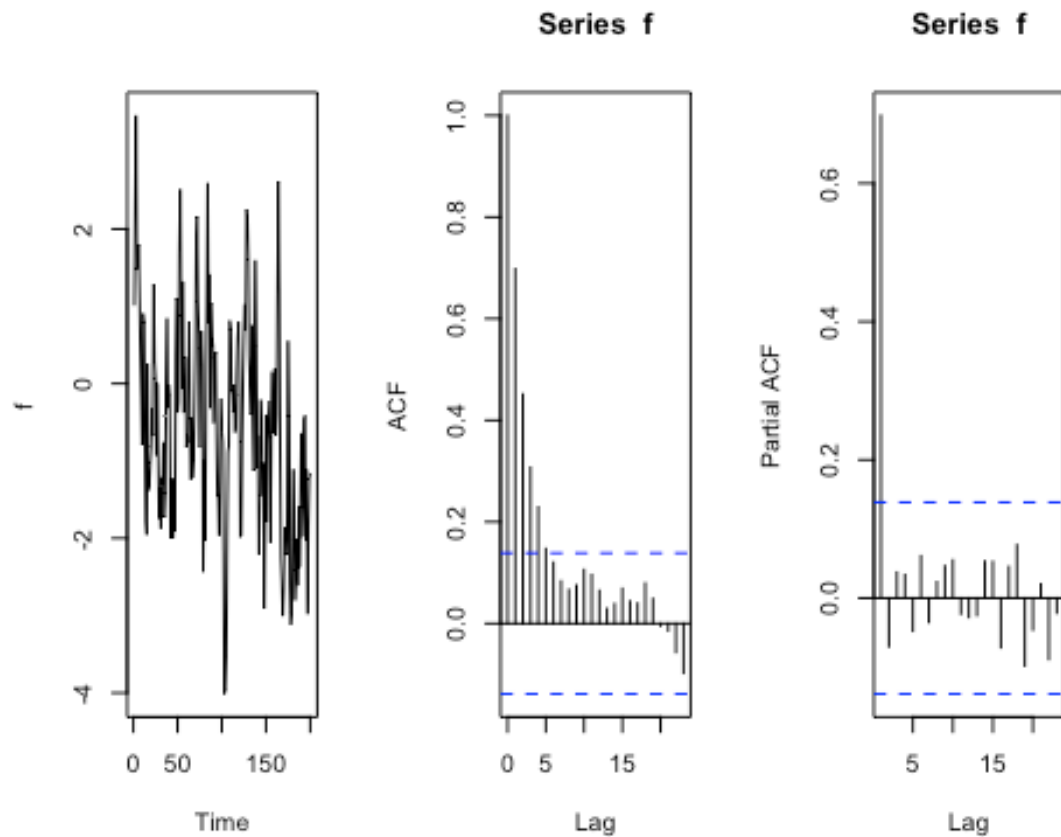
A série não é estacionária

f) Série com correlação de curto-prazo,

$$x_t = 0.7x_{t-1} + N(0, 1)$$

```
par(mfrow = c(1, 3))  
  
f <- arima.sim(model = list(ar = 0.7), n = 200, innov = rnorm(200, 0, 1))  
plot(f)
```

```
acf(f)
pacf(f)
```



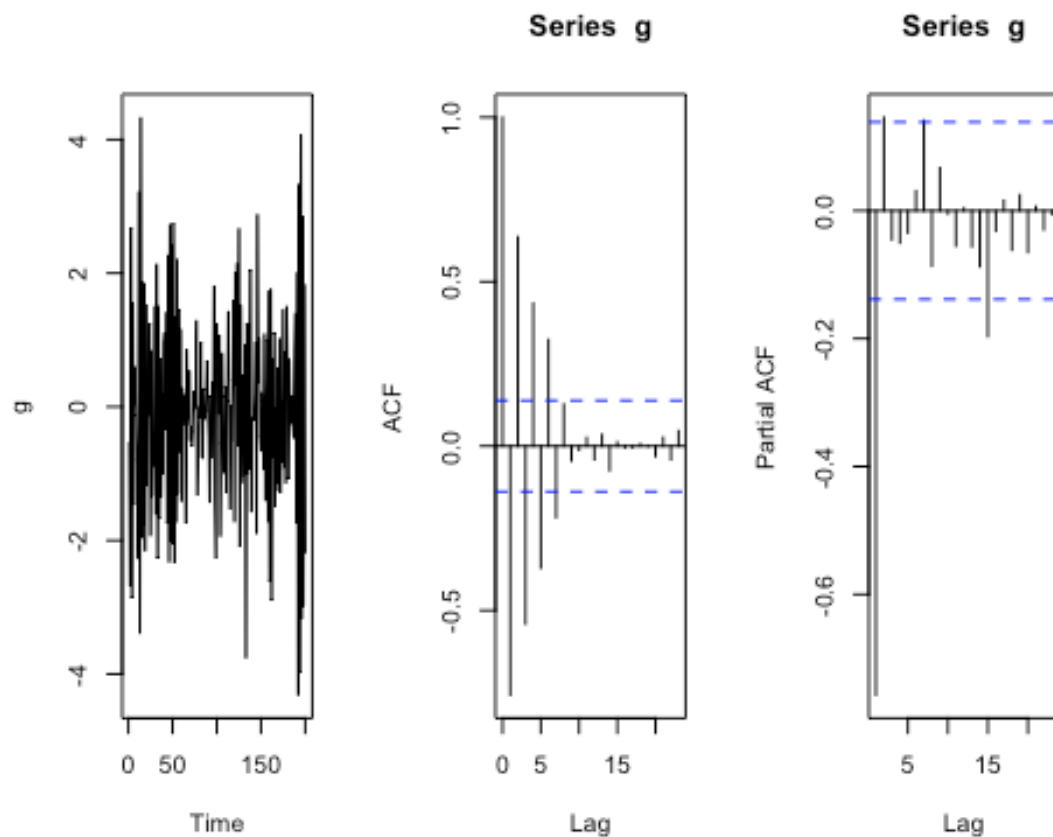
A série é estacionária, ACF com decaimento e grafico de pacf com pico em 1

g) Série com correlações negativas

$$x_t = -0,8x_{t-1} + N(0, 1)$$

```
par(mfrow = c(1, 3))

g <- arima.sim(model = list(ar = -0.8), n = 200, innov = rnorm(200, 0, 1))
plot(g)
acf(g)
pacf(g)
```



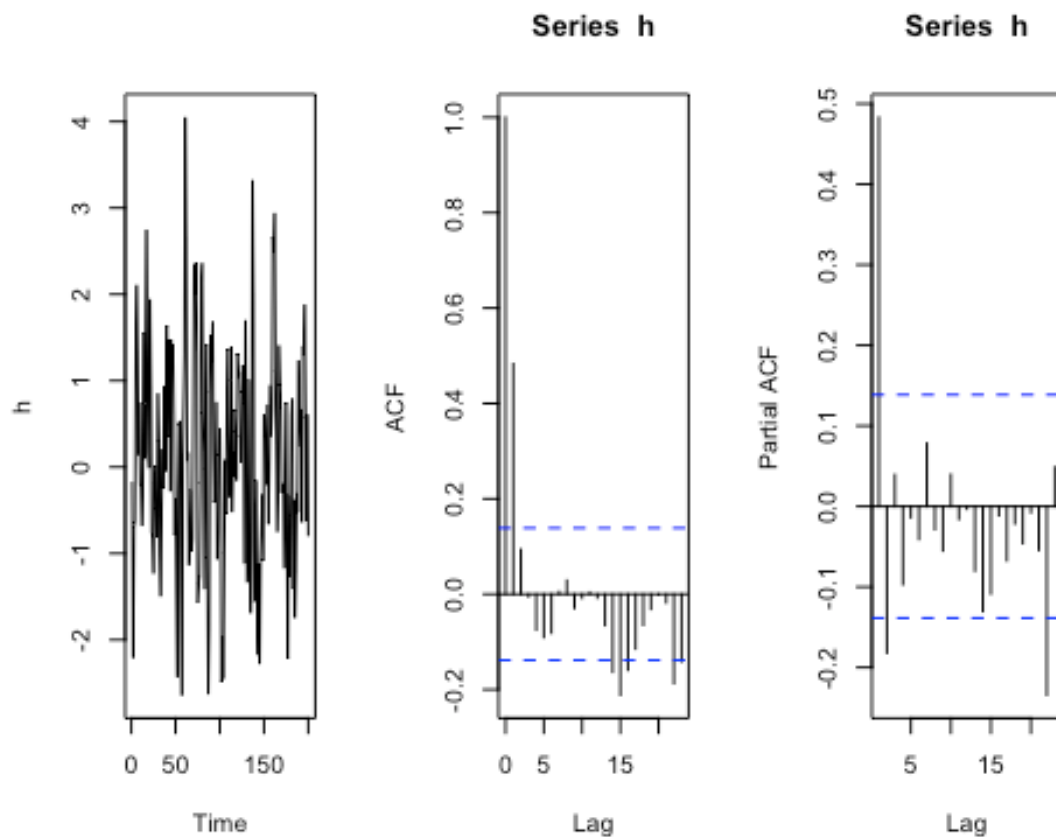
A série é estacionária, acf com decaimento oscilando, pacf pico em 1

h) Médias móveis

$$x_t = \epsilon_t + 0,6\epsilon_{t-1} \quad \epsilon_t \sim N(0, 1)$$

```
par(mfrow = c(1, 3))

h <- arima.sim(model = list(ma = 0.6), n = 200, innov = rnorm(200, 0, 1))
plot(h)
acf(h)
pacf(h)
```



A série é estacionária, acf igual a 0 em $K > 1$ e pacf com decaimento oscilando

3- Utilize a série abaixo para resolver cada item.

An example of a time series that can probably be described using an additive model with a trend and no seasonality is the time series of the annual diameter of women's skirts at the hem, from 1866 to 1911. The data is available in the file <http://robjhyndman.com/tsdldata/roberts/skirts.dat> (original data from Hipel and McLeod, 1994).

```
skirts <- read.table("http://robjhyndman.com/tsdldata/roberts/skirts.dat", header = TRUE, skip = 3)
```

a) Faça a leitura da série de dados e os tratamentos necessários para considerar a mesma como uma série temporal

```
skirts.ts <- ts(skirts, frequency=1, start=c(1866))
#skirts.ts
```

b) Faça a decomposição da série do item (a): Sazonalidade, Tendência e Aleatória.

```
skirts.components <- ifelse(frequency(skirts.ts) > 1,
                             decompose(skirts.ts, type = c("additive", "multiplicative")),
```

```
print("Nao e' possivel decompor uma serie anual, para  
ser feita a decomposicao a serie deveria ter, no minimo, 2 periodos"))
```

```
## [1] "Nao e' possivel decompor uma serie anual, para ser feita a decomposic  
ao a serie deveria ter, no minimo, 2 periodos"
```

```
#plot(skirts.components)
```

c) Calcule a ACF e PACF da série e da primeira diferença


```
par(mfrow = c(2, 2))
```

```
acf(skirts.ts)
```

```
acf(diff(skirts.ts))
```

```
pacf(skirts.ts)
```

```
pacf(diff(skirts.ts))
```



Os ACF da série e da primeira diferença não apresentam muita diferença quando comparados entre si. No gráfico PACF na série apresenta um lag com valor negativo no tempo 2 e na primeira diferença apresenta um lag com valor positivo no tempo 6.

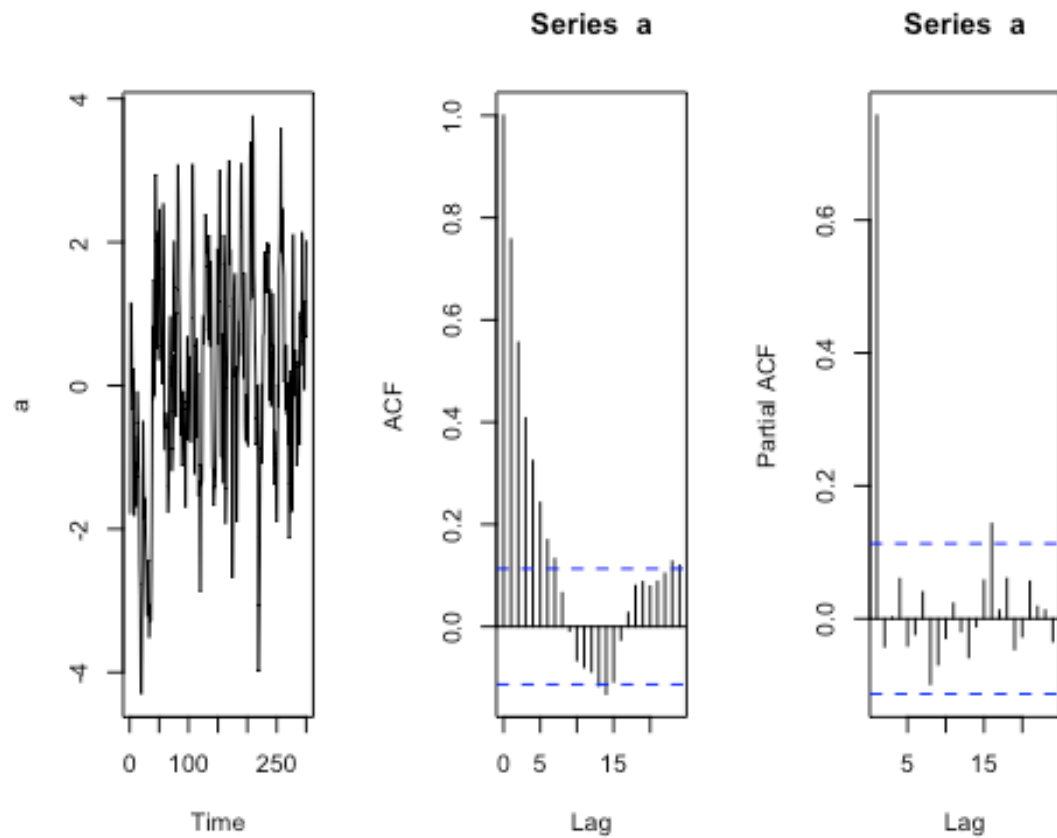
4- Usando a função `arima.sim` gere as seguintes simulações (300 ptos):

```
set.seed(1234)
```

a) Processo AR(1) onde $\theta_0=0, \theta_1=0.7$

```
par(mfrow = c(1, 3))
```

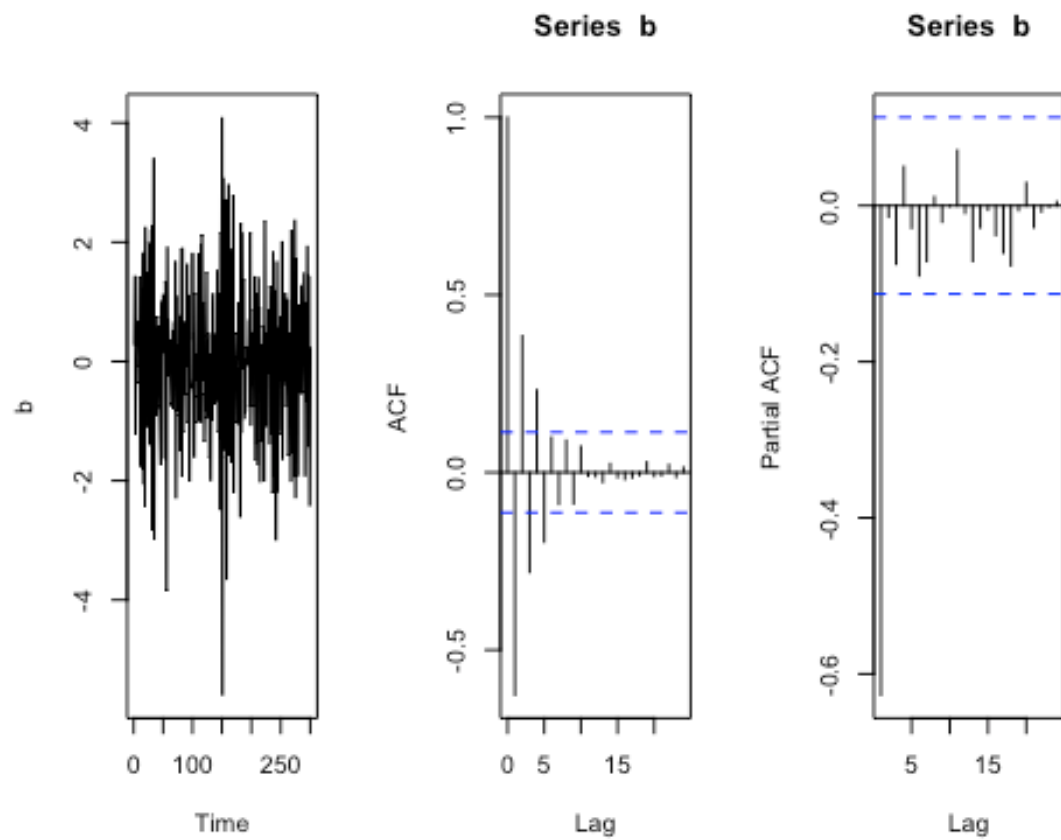
```
a <- arima.sim(n=300,list(ar = c(.7)))  
plot(a)  
acf(a)  
pacf(a)
```



b) Processo AR(1) onde $\theta_0=0, \theta_1=-0.7$

```
par(mfrow = c(1, 3))
```

```
b <- arima.sim(n=300,list(ar = c(-.7)))  
plot(b)  
acf(b)  
pacf(b)
```



c) Processo AR(2) onde $\theta_0=0$, $\theta_1=0.3$ e $\theta_2=0.5$

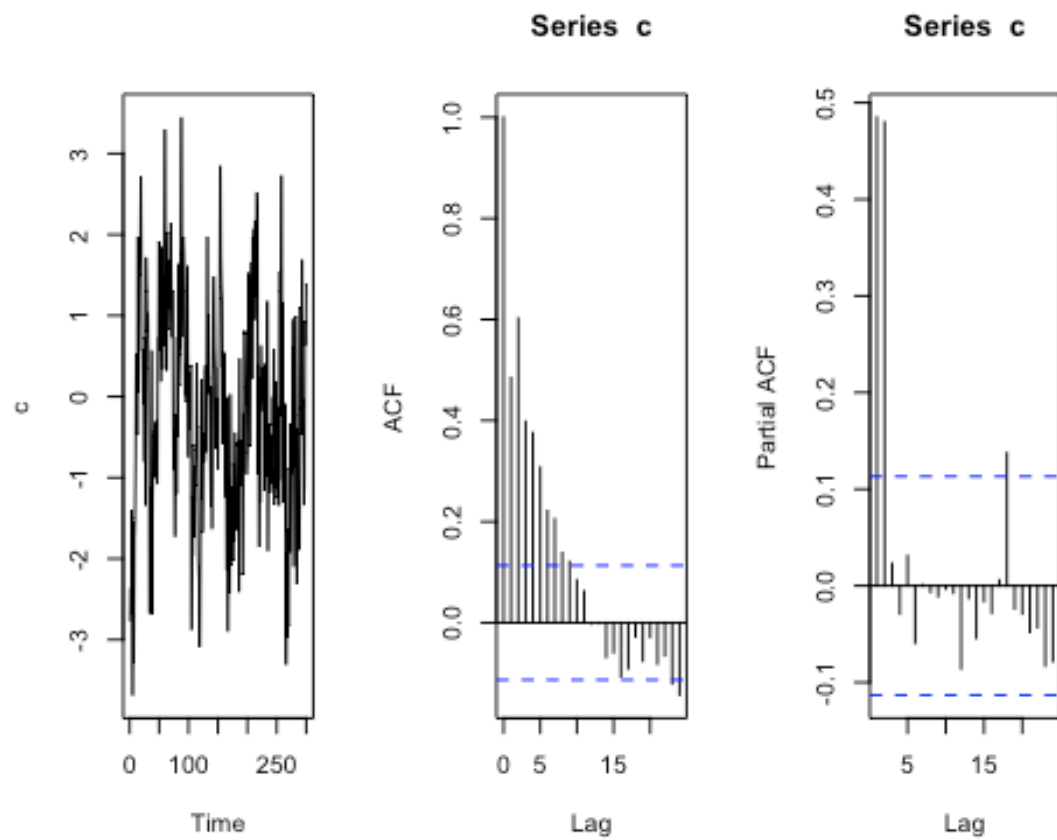
```
par(mfrow = c(1, 3))
```

```
c <- arima.sim(n=300,list(ar = c(.3,.5)))
```

```
plot(c)
```

```
acf(c)
```

```
pacf(c)
```



d) Processo MA(1) onde $\theta_0=0$, $\theta_1=0.6$

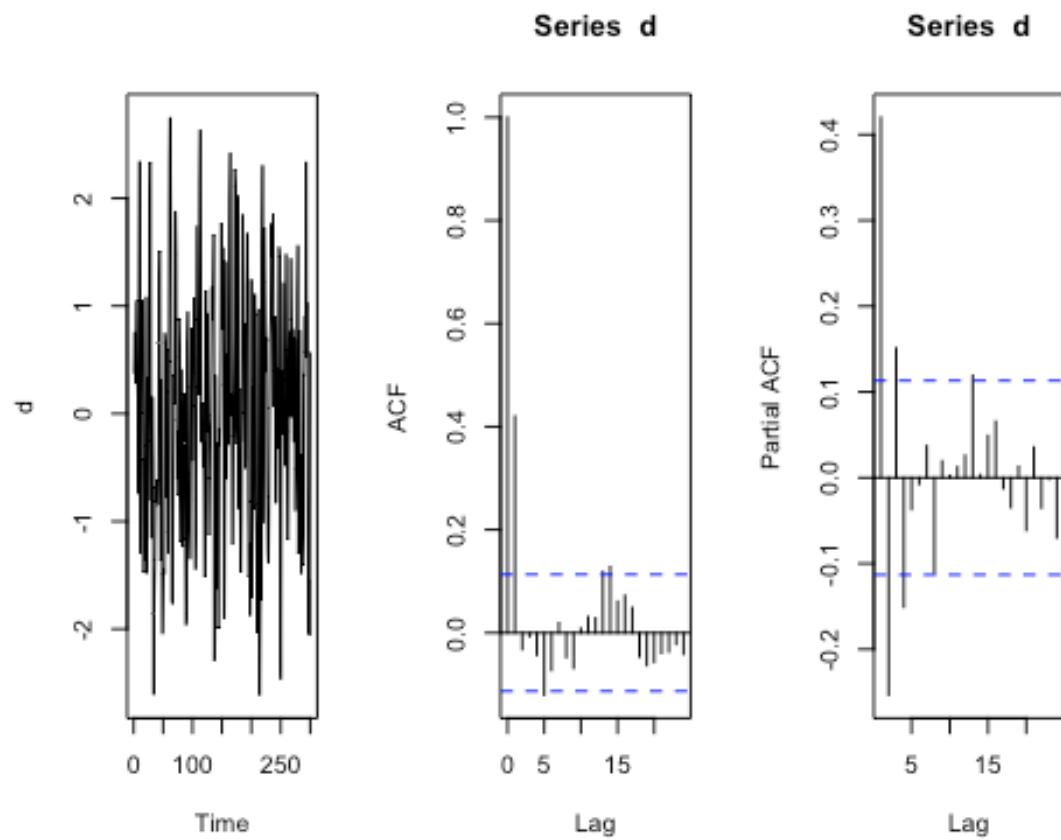
```
par(mfrow = c(1, 3))
```

```
d <- arima.sim(n=300,list(ma = c(.6)))
```

```
plot(d)
```

```
acf(d)
```

```
pacf(d)
```

e) Processo MA(1) onde $\theta_0=0$, $\theta_1=-0.6$

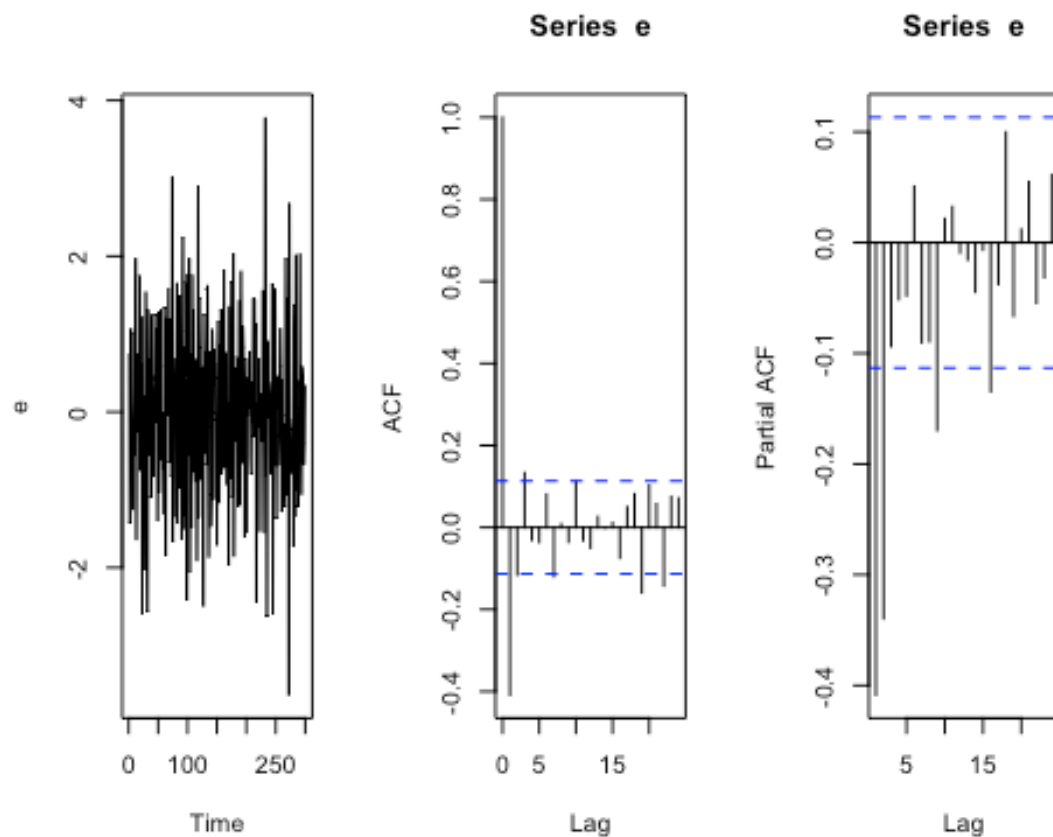
```
par(mfrow = c(1, 3))
```

```
e <- arima.sim(n=300,list(ma = c(-.6)))
```

```
plot(e)
```

```
acf(e)
```

```
pacf(e)
```



Para cada simulação, plote o gráfico da série, calcule o ACF e PACF. Usando estes resultados conclua como deve ser o comportamento da ACF de PACF de um modelo autoregressivo (AR.)

5- Obtenha a série histórica do PIB Brasil no site:

<http://www.bcb.gov.br/pre/portalCidadao/cadsis/series.asp?idpai=PORTALBCB> Código da série: 1232

Lendo o arquivo do PIB (Editado fora do R por comodidade)


```
PIB <- read.csv("PIB2.csv")
#PIB
```

Criando uma Serie Temporal baseado no PIB (data inicio 1 Trimestre de 1991 e frequencia trimestral)

```
PIB.ts<-ts(PIB, frequency=4, start=c(1991,1))
#PIB.ts
```

a) Plote o gráfico da série usando o R

```
plot.ts(PIB.ts)
```




b) Faça a decomposição da série em: Sazonalidade, Tendência e Aleatória.

```
PIB.decomposto <- decompose(PIB.ts)
```

```
#PIB.decomposto
```

```
plot(PIB.decomposto)
```

Decomposition of additive time series



- c) Usando o índice dos últimos 12 anos, encontre uma projeção para o PIB(índice) do próximo semestre usando um modelo AR(1). Neste caso use a série das diferenças.

Usando Predict:

```
if(!require(forecast)) {
  install.packages("forecast")
  library(forecast)
}

## Loading required package: forecast

PIB.dif <- diff(PIB.ts[(nrow(PIB.ts)-12*4):nrow(PIB.ts)])
PIB.predict <- predict(auto.arima(PIB.dif),ahead = 2)
PIB.predict

## $pred
## Time Series:
## Start = 49
## End = 49
## Frequency = 1
## [1] 3.342682
##
## $se
```

```
## Time Series:
## Start = 49
## End = 49
## Frequency = 1
## [1] 3.779094
```

Usando Forecast:

```
etsfit.PIB.dif <- ets(PIB.dif)
etsfit.PIB.dif


## ETS(A,N,N)
##
## Call:
## ets(y = PIB.dif)
##
## Smoothing parameters:
##   alpha = 1e-04
##
## Initial states:
##   l = 1.0451
##
## sigma: 4.3916
##
##      AIC      AICc      BIC
## 331.8250 332.3705 337.4386

accuracy(etsfit.PIB.dif)

##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.03456298 4.299119 3.433323 38.41953 136.8852 0.6138396
##              ACF1
## Training set -0.2304208

fcast.PIB.dif <- forecast(etsfit.PIB.dif, h = 2, level = c(80,95))
#fcast.PIB.dif
plot(fcast.PIB.dif)
```


Forecasts from ETS(A,N,N)



Usando ARIMA:

```
arimafit.PIB.dif <- auto.arima(PIB.dif)
fcast.ARIMA.PIB.dif <- forecast(arimafit.PIB.dif, h = 2, level = c(80,95))
#fcast.ARIMA.PIB.dif
plot(fcast.ARIMA.PIB.dif)
```

Forecasts from ARIMA(0,0,2) with non-zero mean



Usando Forecast (sem usar a diferença):

```
etsfit.PIB.ts <- ets(PIB.ts[(nrow(PIB.ts)-12*4):nrow(PIB.ts)])
etsfit.PIB.ts


## ETS(M,A,N)
##
## Call:
## ets(y = PIB.ts[(nrow(PIB.ts) - 12 * 4):nrow(PIB.ts)])
##
## Smoothing parameters:
##   alpha = 0.2265
##   beta  = 1e-04
##
## Initial states:
##   l = 113.1102
##   b = 1.2088
##
## sigma: 0.0271
##
##      AIC      AICc      BIC
## 329.4144 330.8098 338.8735

accuracy(etsfit.PIB.ts)
```

```
##               ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.1070473 3.774304 2.966711 -0.1073658 2.082458 0.8403785
##               ACF1
## Training set 0.1977401

fcast.PIB.ts <- forecast(etsfit.PIB.ts, h = 2, level = c(80,95))
#fcast.PIB.ts
plot(fcast.PIB.ts)
```

Forecasts from ETS(M,A,N)



Usando ARIMA (sem usar a diferença):

```
arimafit.PIB.ts <- auto.arima(PIB.ts[(nrow(PIB.ts)-12*4):nrow(PIB.ts)])
fcast.ARIMA.PIB.ts <- forecast(arimafit.PIB.ts, h = 2, level = c(80,95))
#fcast.ARIMA.PIB.ts
plot(fcast.ARIMA.PIB.ts)
```


Forecasts from ARIMA(0,1,2) with drift

